

1. Тема дослідження: Автоматизована перевірка текстових робіт за допомогою ШІ. Такі підходи використовуються для зменшення навантаження на вчителів\викладачів та збільшення їх вільного часу, через проблеми суб'єктивності та непослідовності оцінювання робіт людиною, особливо під час втоми. Крім цього, загальна швидкість перевірки значно вища, ніж людська, а збережений час можна використати для покращення самих робіт і підходів до викладання. Одним із прикладів такої системи перевірки на платформі Coursera, де ШІ виконує оцінювання завдань за певними рубриками і може надавати розгорнутий відгук студенту про роботу, її недоліки та сильні сторони і що можна покращити. Для роботи системи потрібно виконати початкове налаштування під певну дисципліну, як то створення запиту, надання прикладів робіт тощо. Також роботу цих систем можна коригувати та змінювати результати перевірки за потреби.

2. Використані джерела:

Для аналізу даної тематики були використані такі джерела:

- 1) Штучний інтелект оцінює роботи учнів нарівні з учителями, але має обмеження
- 2) A survey of automated essay scoring: Challenges, advances, and future
- 3) A Comprehensive Review on Automated Grading Systems in STEM Using AI Techniques
- 4) Faculty members' use of artificial intelligence to grade student papers: a case of implications

3. Основні підходи та принципи:

- 1) Prompt-інженерія: використання правильних запитів до великих мовних моделей з наданим контекстом у запиті, дається робота на оцінювання. Для ШІ виділяються конкретні рубрики та система оцінювання, за якими він має оцінити роботу, що підвищує точність. Надання інструкцій моделі щодо того, як має перевірятися робота або надання інструкції і кількох прикладів перевірки (zero-shot та few-shot підходи відповідно), надання запитів із вказанням конкретних кроків, які має виконати ШІ для перевірки роботи (наприклад: надання ролі, опису завдання і рубрик оцінювання, надання інструкції для оцінювання та надання прикладів оцінювання) тим самим змушуючи модель працювати в режимі ланцюжка думок.
- 2) Fine-tuning: дотреновування частини ваг великої мовної моделі на даних під специфічну сферу\задачу. Тренувальний датасет містить пари запитів та очікуваних відповідей. За рахунок тренувань модель починає краще відповідати на специфічні запити, наприклад щодо фізики. На вхід подаються запитання щодо певної теми, а в очікуванні відповіді на поставлене питання міститься відповідна теорія. Фактично знання "вшиваються" у ваги моделі.

4. Проблеми та гіпотези:

Незважаючи на переваги цих методу перевірки, є певні проблеми та питання, які можуть виникнути:

- 1) Залежність від якості і розміру датасету: для якісної роботи таких систем потрібен якісний датасет з великою кількістю різноманітних даних, яких може не бути в потрібній кількості в результаті звичайних перевірок робіт.
- 2) Можливість обходу правил оцінювання студентами задля отримання вищого балу: знаючи правила та інструкції, за якими оцінюються роботи, можна створити роботи таким чином, які формально відповідають критеріям, але насправді не є коректними.
- 3) Складність під час постійного створення запитів для перевірки: під час використання великих мовних моделей, потрібно витратити час для створення та перевірку правильних запитів, надання матеріалу для перевірки в ньому, на що потрібно витратити певний час.

4) Приватність і безпека даних: потрібно зберігати конфіденційність даних при використанні таких систем, оскільки роботи можуть містити особисту інформацію студентів, як то ПІБ, група, оцінка за цю роботу після перевірки тощо. У випадку використання сторонніх сервісів потрібно убезпечити, що дані викладачів та студентів не передаються третім особам, а самі роботи не використовуються деінде без відома, як зберігаються на серверах тощо. Також потрібно убезпечитися у разі наявності небезпечного вмісту в самих роботах, наприклад, специфічний текст, який може змусити модель дати некоректну відповідь, або поділитися певною інформацією(як приклад з “бабусею і ключами до віндос”, коли певними маніпуляціями користувач зміг отримати робочі ключі до віндос безкоштовно).

5) Упередженості та неточності моделі: оскільки великі мовні моделі тренувалися на даних, взятих з інтернету, які створені великою кількістю людей, модель може переймати упередження, які містяться в цих даних. Також моделі можуть виконувати непотрібні перевірки, відходити від контексту, додавати у відповідь “зайвого”, чого не було задано у початковому запиті, якщо це не було обмежено контекстом, робити припущення про знання студентів, які вони насправді не мають.

6) Інтеграція в систему закладу освіти: розроблену систему потрібно інтегрувати в поточну систему освітнього процесу, у разі автоматичного виставлення оцінок системою можуть бути проблеми з некоректним оцінюванням.

5. Ідеї та підходи для вирішення цих проблем:

1) Використання систем із RAG: за відсутності достатньої кількості робіт для створення тренувального датасету, але за достатньої кількості даних про певну сферу, якої стосуються роботи студентів (документи, лекції, книжки, статті тощо) можна завантажити їх у векторну базу даних і , використовуючи разом із prompt-інжинірингом, дані, знайдені за запитом, будуть автоматично діставатися з цієї бази та вставлятися у запит у вигляді контексту, тим самим обмежуючи кількість зайвої інформації, яку може використати модель під час відповіді і надаючи потрібну для перевірки роботи. Наприклад, для кожного завдання модель отримає дані з лекцій, де може міститися інформація про розв’язання певних задач, чи дістане інформацію по предметній області за темою, метою та поставленими задачами в роботі.

2) Сервіс-посередник для забезпечення безпеки: сервіс, який перед відправкою робіт до системи перевірки ШІ буде виконувати приховування чи зміну даних користувачів, наприклад групи та ПІБ студентів і викладачів, таким чином уникаючи надання справжніх даних. Виставлення балів ШІ також буде відбуватися саме в цей сервіс, а не безпосередньо в систему закладу освіти, ці бали потім можна перенести. Крім цього, перед безпосередньої відправкою робіт до системи перевірки, роботи перевірятимуться на наявність шкідливого\некоректного вмісту за допомогою NLP, семантичного аналізу, інструментів автоматичної модерації чи інших ШІ, здатних виявляти цей вміст.